

Influència dels hàbits i les característiques individuals en el pes corporal

Anna Mongelos Amill^a and Natàlia Navarro Riera^b

^a1672531

^b1711044

1. Introducció

En aquest treball s'analitza una base de dades que indica el grau d'obesitat d'un pacient. El 80% de la base de dades el farem servir per l'entrenament i la validació creuada (training). Aquest conté informació de 1688 pacients. Per altra banda, el 20% restant s'ha utilitzat per fer el test final, amb 423 pacients. L'objectiu és estudiar i preparar les dades per poder predir l'estat de salut del pacient en funció de diversos hàbits del seu dia a dia així com també l'edat, sexe i historial familiar. Es tracten variables desbalancejades, se seleccionen les variables més rellevants i es construeixen models predictius per obtenir conclusions sobre els factors que més influeixen en el pes.

2. Anàlisi exploratòria de dades

La base de dades conté 17 atributs, un dels quals és la variable `NObesidad`, que volem predir. La variable explicativa està formada per les següents categories: `Insufficient_Weight`, `Normal_Weight`, `Obesity_type_I`, `Obesity_type_II`, `Obesity_type_III`, `Overweight_Level_I`, `Overweight_Level_II`.

Davant la incertesa de si aquesta és categòrica o ordinal hem decidit entrenar un model per regressió i un altre per classificació per, finalment, comparar el rendiment dels dos models i decidir quin és el millor.

No podem assegurar que la distància entre els diferents pesos sigui comparable. Per exemple, la distància entre infrapes i pes estàndard no es pot descartar ni afirmar que sigui la mateixa que entre dos graus d'obesitat. Per aquest motiu hem considerat les dues opcions: un model que assumeix distàncies equidistants entre categories (regressió), i un model que no té en compte les distàncies (classificació).

Els valors d'aquesta variable estan calculats per la fórmula de l'IMC (índex de massa corporal):

$$IMC = \frac{Pes}{Alçada^2}$$

A l'hora d'escollir fer aquest estudi el nostre objectiu ha estat relacionar el tipus de pes amb els hàbits i les característiques individuals, per tant, hem decidit descartar dues variables d'entrada que són el `Pes` (exacte) i l'`Alçada`, ja que tenen relació molt directa amb la variable que volem predir.

Els 14 atributs restants, hem analitzat quin comportament tenen en vers de la variable resposta. Aquests atributs es poden classificar en dos grups principals:

Variables categòriques

- **Gender** : Tots els tipus d'obesitat influeixen bastant igual en genere, menys quan tenim `obesitat_tipus_III` que només tenim dones, i `Obesitat_tipus_II` només tenim homes.
- **family_history_with_overweight** : Veiem que tots els casos de persones amb obesitat (tipus I, II, III) i sobre pes nivell II només es donen quan hi ha historial familiar.
- **FAVC (consum freqüent d'aliments en calories)**: Els casos amb obesitat més severa consumeixen aliments alts en calories amb més freqüència. Contràriament, els pacients que consumeixen menys calories coincideixen amb els casos de menys obesitat.

- **CAEC (menjar entre àpats)**: La variable està desequilibrada, té molt pocs casos a `No` i `Always`, per tant, els agrupem en les categories similars, quedant "`Freq` o `always`" i "`Sometimes` o `no`". La categoria "`Freq` o `Always`" només té casos de pes estàndard o insuficient. Creiem que aquesta variable pot estar afectada per una certa subjectivitat dels pacients, els quals tenen diferents percepcions sobre els seus hàbits alimentaris
- **SMOKE**: Veiem que la resposta "`No`" de la variable fumar només té un 2,2% de representació, és a dir, està molt desequilibrada i, per tant, decidim eliminar la variable.
- **SCC (monitorització consum de calories)**: Els casos amb obesitat o més sobrepès no tenen un seguiment de les calories ingerides. Tot i que, no és molt fiable perquè la variable està molt desbalancejada.
- **CALC (consum d'alcohol)**: Tots els casos d'obesitat tipus_III beuen alcohol de vegades. Entre els casos que no beuen alcohol podem destacar obesitat del tipus_I.
- **MTRANS (mitjà de transport)**: Tenim pocs casos de Caminar, Bici i Moto, els agrupem amb una categoria nova "`Altres`". El transport públic és el transport més utilitzat. El cas de la obesitat III només utilitza aquest transport, la resta d'obesitat s'hi suma el transport de l'automòbil. I els transports que hi ha més exercici "`Altres`" destaquen els casos amb el pes normal.

Variables numèriques

- **Age**: La majoria de pesos es centren als voltants dels 20 anys, menys les obesitats del tipus II i III. L'`obesitat_tipus_II` està repartida entre els 20 i els 35 anys i l'`obesitat_tipus_III` té molts casos en els 27 anys i alguns una mica abans.
- **FCVC (freqüència del consum de verdures)**: Els casos de pes insuficient mengen amb més freqüència verdures en els seus àpats. I els casos d'`obesitat_tipus_I` mengen amb menys freqüència.
- **NCP (nombre d'àpats)**: Aquesta variable aportarà poca informació sobre el pes corporal, ja que la majoria de persones, independentment del seu pes, han respost que fan tres àpats al dia.
- **CH20 (consum d'aigua)**: La major part de persones, independentment del seu pes, consumeixen al voltant d'uns 2L d'aigua al dia. Hi ha un pic de casos d'obesitat de tipus III al voltant dels 2.5-3L al dia. Igualment, a simple vista, no podem identificar cap patró clar que relacioni el consum d'aigua amb el pes.
- **FAF (freqüència d'activitat física)**: En aquesta variable identifiquem que la majoria de casos d'obesitat de tipus II es donen en persones que no tenen l'hàbit de fer activitat física. Aquesta observació contrasta amb els casos d'infrapes, que predominen entre els pacients que fan més activitat física.
- **TUE (temps d'ús de dispositiu tecnològic)**: La majoria dels casos són bastant iguals. La majoria de casos d'obesitat de tipus III se centren a 1, mentre que la resta estan repartits entre 0 i 1. Així que inicialment no podem extreure-hi cap comportament específic d'aquesta variable.

3. Preprocessament

Després de veure les dades que disposem, hem de fer algunes modificacions per preparar el model. Les variables categòriques s'han de passar a numèriques. MTRANS té tres categories: Altres, automòbil i transport públic. Hem aplicat *one-hot encoding* per separar-les en tres variables diferents: MTRANS_ALTRES; MTRANS_Automobile; MTRANS_Public_Transportation. Per les altres variables categòriques hem fet les següents modificacions:

- **Gender:** Male: 1, Female: 0
- **family_history_with_overweight:** yes: 1, no: 0
- **FAVC:** yes: 1; no: 0
- **SCC:** yes: 1; no: 0
- **CALC:** Freq o always: 2; Sometimes: 1; no: 0
- **CAEC:** Freq o always: 1; Sometimes o no: 0

Respecte la variable resposta, aquesta tindrà una assignació diferent segons l'enfoc del problema (regressió/classificació).

Quan fem regressió suposem que les categories de la variable segueixen un ordre. Per tant hem fet la següent assignació, Insufficient_Weight: 0, Normal_Weight: 1, Overweight_Level_I: 2, Overweight_Level_II: 3, Obesity_Type_I: 4, Obesity_Type_II: 5, Obesity_Type_III: 6

En el cas de classificació hem fet *label encoding*, una assignació numèrica de les classes sense seguir cap ordre específic. Insufficient_Weight: 0, Normal_Weight: 1, Overweight_Level_I: 5, Overweight_Level_II: 6, Obesity_Type_I: 2, Obesity_Type_II: 3, Obesity_Type_III: 4

3.1. Correlacions entre variables




Figure 1. Correlacions entre variables

Per estudiar les correlacions amb la variable objectiu, les variables categòriques s'han transformat en valors numèrics. D'aquest anàlisi se'n desprèn que les variables MTRANS_Automobile i MTRANS_Public_Transportation estan inversament correlacionades. L'edat està directament correlacionada amb l'automòbil com a mitjà de transport mentre que pel que fa al transport públic, la correlació amb la variable és inversa.

Pel que fa a NObeyesdad, l'assignació numèrica de les diferents categories depèn de si estem en el cas de regressió o classificació.

Per regressió les variables que tenen més correlació són CAEC (inversament) i family_history_with_overweight. Paral·lelament, a classificació l'assignació es fa de manera aleatòria. Per tant, tot i que les variables tenen el mateix comportament, al no seguir cap ordre és més difícil la interpretació de les correlacions.

És important que a l'hora d'entrenar el model totes les variables prenguin valors dins d'una mateixa escala (o similar) per tal de poder fer comparacions més robustes. Per solucionar la diferència, farem una normalització de tipus *z-score*, en cas de no fer-la, durant el procés d'aprenentatge prendria més importància la variable AGE, distorsionant el model, a causa dels seus valors elevats.

4. Regressió

La regressió és un tipus de modelatge predictiu en què l'objectiu és predir un valor numèric continu. A diferència de la classificació, aquí l'ordre i la magnitud dels valors tenen importància.

Hem transformat la variable resposta a numèrica seguint l'ordre donat, i per conèixer la classe predita hem arrodonit el valor al nombre enter (de 0 a 6).

4.1. Selecció de mètriques

Per avaluar el rendiment dels models en regressió, hem considerat les mètriques MSE, RMSE, MAE i R^2 . La mètrica que s'ajusta més al nostre problema és **RMSE**. És útil perquè penalitza més els errors grans evitant prediccions dolentes i, a més a més, torna les distàncies a l'escala natural, sent així més interpretable. El millor model serà el que tingui el valor mínim de RMSE.

4.2. Selecció de models amb validació creuada

Per aquest apartat considerem 5 models a comparar, Regressió Lineal, Random Forest, XGBoost, LightGBM i SVM.

Per comparar el rendiment hem aplicat la validació creuada amb 5 particions del train, fent servir la mètrica RMSE. Per tenir una primera impressió, mirem el rendiment utilitzant els hiperparàmetres per defecte de cada model. Obtenim els següents resultats:

Model	Validació RMSE (mitjana)	Temps total (s)
Regressió lineal	1.366429	0.0175
Random Forest	0.736816	1.8605
XGBoost	0.768915	0.5760
LightGBM	0.753404	0.4451
SVM	0.833113	0.3250

Table 1. Comparació de models amb RMSE (validació creuada 5-fold)




Figure 2. Visualització dels rangs dels RMSE dels algorismes

De moment amb els hiperparàmetres per defecte obtenim millors resultats amb els algorismes Random Forest, XGBoost i LightGBM.

Veiem que Regressió Lineal, tot i ser l'algoritme més ràpid, és amb el que obtenim un valor més elevat, amb diferència, de RMSE. Per tant descartem els algoritmes Regressió Lineal i SVM.

D'aquesta manera farem la cerca d'hiperparàmetres dels models més prometedors. Així estalviem temps de computació amb l'objectiu d'obtenir un valor de RMSE més baix.

Es tracta d'una cerca exhaustiva (*Grid Search*) en la que es consideren totes les combinacions possibles d'hiperparàmetres per cada model i s'escull aquella combinació amb millor rendiment.

De l'algorisme Random Forest hem considerat els següents hiperparàmetres:

- `n_estimators`: 50, 100, 200
- `max_depth`: 10, 20, sense límit de profunditat (none)
- `min_samples_split`: 2 o 5

Per XGBoost:

- `n_estimators`: 50, 100, 200
- `max_depth`: 3, 5, 10
- `learning_rate`: 0.01, 0.1, 0.2
- `subsample`: 0.7, 1.0

Per LightGBM:

- `n_estimators`: 50, 100, 200
- `max_depth`: 3, 5, 10
- `learning_rate`: 0.01, 0.1, 0.2
- `num_leaves`: 31, 50, 100

Tornem a fer validació creuada de 5 particions i comparem:

Validació RMSE		
Model	(mitjana)	Temps total (s)
RandomForest	0.721719	6.0157
XGBoost	0.715926	2.2428
LightGBM	0.750854	8.9719

Table 2. Comparació de models amb RMSE (validació creuada 5-fold




Figure 3. Visualització dels rangs dels RMSE dels algoritmes amb hiperparàmetres òptims

En general, tots els models mostren una millora en la mètrica de regressió després d'ajustar els hiperparàmetres òptims. El model que continua oferint els millors resultats és el XGBoost. La combinació d'hiperparàmetres pel model és: `'learning_rate': 0.1`, `'max_depth': 10`, `'n_estimators': 100`, `'subsample': 0.7`

4.3. Test

Inicialment, vam dividir el dataset en dos: un 80% l'hem utilitzat per fer l'entrenament i la validació, l'altre 20% l'utilitzem per fer el test final. Abans de fer la predicció sobre aquest conjunt hem netejat les dades igual que en la fase d'entrenament.

Al fer el test estem introduint noves dades al nostre model, això ens servirà per detectar si tenim un cas d'*overfitting* on el model s'ajusta bé a les dades d'entrenament però amb dades noves fa molt males prediccions.

Veiem l'error del XGBoost en ambdós casos, amb les dades d'entrenament i amb dades noves:

Mètrica	Training	Test
RMSE	0.715926	0.760467

L'error es manté estable, per tant descartem que tinguem *overfitting* i, per tant, podem dir que el model generalitza bé.

5. Classificació

La classificació és un tipus de modelatge que aprèn a predir classes discretes, per fer-ho necessita tenir la variable numèrica i no té importància l'ordre. En el nostre cas hem volgut assegurar-nos i hem fet l'assignació aleatòria amb el Label Encoding.

5.1. Selecció de mètriques

Pel cas de classificació, volem conèixer amb el mateix nivell d'importància tots els tipus d'errors i encerts (falsos positius, falsos negatius, veritables positius i veritables negatius), per tant creiem que F1-score i accuracy poden ser dues mètriques adequades.

F1-score és molt útil quan les classes estan desbalancejades, però en estar equilibrades i no prioritzar cap classe per sobre de les altres, hem decidit utilitzar **accuracy**. Així ens podem beneficiar de la seva interpretabilitat, ja que els resultats d'accuracy són més fàcils d'interpretar que el F1-score.

L'accuracy mesura percentatge de prediccions correctes sobre totes les mostres, per tant ens interessen valors elevats.

5.2. Selecció de models amb validació creuada

Compararem el rendiment de 6 models diferents: Random Forest, XGBoost, LightGBM, SVM, KNN, Regressió Logística. Com es tracta d'una classificació multiclasse, i SVM i Regressió Logística es basen en prediccions binàries, hem abordat aquests dos algoritmes amb la tècnica *One-vs-Rest*. Per tant, en aquests dos casos estarem entrenant tants classificadors binaris com classes tenim, 6.

Sense fer cap modificació als hiperparàmetres, amb la validació creuada obtenim una primera impressió de quins models retornaran millors prediccions.

Validació accuracy		
Model	(mitjana)	Temps total (s)
Random Forest	0.845	0.8871
LightGBM	0.832	3.8829
XGBoost	0.820	1.4107
SVM (OvR)	0.739	0.6147
KNN	0.746	0.0583
LogisticRegression (OvR)	0.572	0.1404

Table 3. Comparació de models amb accuracy (validació creuada 5-fold)

Veiem una representació més visual:




Figure 4. Visualització dels rangs dels accuracy dels algoritmes




Figure 5. Visualització dels rangs dels accuracy dels algoritmes amb hiperparàmetres òptims

De moment podem descartar la Regressió Logística per un valor de la mètrica molt dolent en comparació a la resta. Pel que fa als altres models, com la diferència de l'accuracy no és tan marcada, de moment els conservem.

Fem cerca d'hiperparàmetres per veure si es pot millorar el rendiment. Aquesta cerca la fem de forma aleatòria, on hi ha un nombre determinat de combinacions per rebaixar els costos computacionals ja que tenim models que utilitzen la tècnica *One-vs-Rest* que tenen un cost computacional molt elevat.

De l'algorisme Random Forest hem considerat els següents hiperparàmetres:

- `n_estimators`: 100, 200, 300
- `max_depth`: 5, 10, 20, sense límit de profunditat (none)
- `min_samples_split`: 2, 5, 10

Per XGBoost:

- `n_estimators`: 100, 200, 400
- `max_depth`: 3, 5, 10
- `learning_rate`: 0.01, 0.1, 0.2

Per LightGBM:

- `n_estimators`: 100, 200, 400
- `max_depth`: 5, 10, 15
- `learning_rate`: 0.01, 0.05, 0.1
- `num_leaves`: 15, 31, 63

Per SVM:

- `C`: 0.1, 1, 10, 100
- `kernel`: linear, rbf, poly
- `gamma`: scale, auto

Per KNN:

- `n_neighbors`: 5, 7, 9, 11, 13, 15
- `weights`: uniform, distance
- `metric`: euclidean, manhattan, minkowski, chebyshev

A partir de la validació creuada hem identificat que el model amb el qual s'obté una accuracy més elevada és RandomForest amb la combinació d'hiperparàmetres: `'n_estimators': 100`, `'min_samples_split': 2`, `max_depth: None`.

Validació accuracy		
Model	(mitjana)	Temps total (s)
RandomForest	0.843569	4.2188
XGBoost	0.834734	2.1644
LightGBM	0.824067	3.4401
SVC	0.792069	0.4419
KNN	0.790306	0.0658

Table 4. Comparació de models amb RMSE (validació creuada 5-fold)

5.3. Test

Per comprovar si el model seleccionat és bo i generalitza correctament, utilitzem un conjunt de dades de test (20%) que es va separar al principi i que el model no ha vist mai durant l'entrenament. Apliquem la mateixa mètrica que hem emprat durant el procés d'avaluació per mesurar el seu rendiment. Abans de fer les prediccions, les dades del test s'han netejat i preprocessat seguint exactament els mateixos passos que amb les dades d'entrenament, per garantir la coherència i evitar inconsistències. Els resultats realitzats són els següents:

Mètrica	Train	Test
Accuracy	0.853427	0.862884

Podem verificar que tenim un model robust amb un accuracy bastant alt i sense *overfitting*.




Figure 6. Matriu de Confusió de Classificació

6. Canvi de regressió a classificació

Un cop tenim els models de regressió i classificació entrenats, volem veure quin és el que fa millors prediccions. Per a fer la comparació entre els dos, hem decidit fer-ho mitjançant la mètrica de classificació, l'**accuracy**.

Com compararem els rendiments sobre el conjunt de dades del test, primer fem les nostres prediccions sobre les noves dades amb el model escollit, XGBoost. Amb aquestes prediccions fetes, arrodonim

els valors continus predits en nombres enters. D'aquesta manera, apliquem l'accuracy sobre les respostes del test i obtenim els resultats,




Figure 7. Matriu de Confusió de "Regressió"

7. Anàlisi final

Ara que tenim els dos models entrenats, comparem el seu rendiment.

Mètrica	Regressió	Classificació
Accuracy	0.739952	0.862884

Hem decidit adoptar com a model final el **Random Forest** de classificació, ja que després de les proves realitzades ha demostrat un rendiment sòlid i equilibrat, mostrant les mètriques més elevades entre els models provats.

Per veure com ha predit el model RandomForest cada classe ens fixarem en la matriu de confusió. Veiem les prediccions correctes, incorrectes i el percentatge d'encert:

Classe	Correctes (TP)	Incorrectes	Encert
Pes insuficient	49	5	90.74%
Pes normal	47	11	81.03%
Sobrepès Tipus I	44	14	75.86%
Sobrepès Tipus II	46	12	79.31%
Obesitat Tipus I	59	11	84.29%
Obesitat Tipus II	56	4	93.33%
Obesitat Tipus III	64	1	98.46%

Table 5. Valors predits segons la classe de test

El model classifica de manera excel·lent les categories d'obesitat més severes (Tipus II i III) i mostra un bon rendiment en les categories de baix risc (Pes insuficient i Pes normal). Això es deu al fet que aquestes categories presenten patrons o característiques més distintives, ja siguin positives o negatives, que faciliten la separació per part del model.

Per tant, es pot inferir que les persones amb un pes més elevat tendeixen a presentar determinats comportaments o trets que contribueixen a aquesta condició, mentre que les categories de baix pes també tenen patrons característics que les diferencien clarament.

A continuació tenim una visualització de la importància de cada variable sobre el model.




Figure 8. Gràfic de barres amb el pes de cada variable del model

La importància global de cada variable queda representada per la longitud de les barres. Les característiques amb més impacte són el consum de verdures (FCVC), l'edat, gènere i l'historial familiar, mentre que variables com el mitjà de transport i la monitorització de consum de calories mostren una influència gairebé nul·la.

Així doncs, podem concloure amb una precisió aproximada de **0.86** que el consum de verdures és el factor que més contribueix a diferenciar entre els diferents nivells d'obesitat, amb un rendiment especialment robust per la categoria de més pes corporal.

En resum, el model de **Random Forest** demostra un rendiment sòlid tant en el conjunt d'entrenament com en el test final oferint una bona capacitat predictiva sobre el pes corporal dels pacients segons els seus hàbits.